

Automatic Differentiation

Jakub Vokoun

Abstract—This paper provides an explanation of Automatic Differentiation (AD) concept for university students at near-bachelor level. Includes comparison with other differentiation methods, very simple AD implementation example and more realistic usage in python library.

Index Terms—autodiff, python, computational mathematics

I. INTRODUCTION

TODO: co je to za problém ta derivace, diferenciace, motivačně kde všude se hodí a proč, jak se počítá ručně

II. BACKGROUND

TODO: proč se na to hodí použít počítač, fundamentální problém (zdrojový kód přesně nekopíruje matematické funkce), možná zase motivace

III. ALTERNATIVE DIFFERENTIATION METHODS

TODO: že existují nějaký další metody, na něco se hodí možná

A. Finite difference method

TODO: co je FD (finite difference) metoda, jak funguje, plusy a minusy

B. Symbolic method

TODO: co je symbolická metoda, jak funguje, plusy a minusy

C. Comparison

TODO: tabulka s porovnáním + vysvětlení proč

IV. AUTOMATIC DIFFERENTIATION

TODO: že existují dvě varianty, začneme tím, co mají společného

A. Core principles

TODO: proč to funguje, teorie za tím

TODO: chain rule, výpočetní graf, potřeba mít známé funkce a jejich derivace

TODO: “jediný” rozdíl mezi FM/BM je pořadí derivací v chain rule - dá se vysvětlit i jako pořadí násobení jakobiánů

B. Forward mode: The tangent linear mode

TODO: důležitý je “přenášení” derivací spolu s hodnotou ve výpočtu

TODO: duální čísla $\epsilon^2 = 0$ jako další matematický pohled na věc

TODO: vhodné pro málo vstupů, hodně výstupů - pro každý vstup třeba další průchod

C. Backward mode: The adjoint mode

TODO: potřeba dva průchody - první k vytvoření výpočetního grafu a zpětný k tomu, abychom viděli jak který vstup kontributuje k výsledné hodnotě (kterou si zvolíme) -> víc paměti. taky VJP (vector jacobian product) - a na tom ukázat, že je vhodné pro mnoho vstupů a málo výstupů (vs forward mode)

D. Computational complexity

TODO: časová a paměťová komplexita, porovnání s ostatními metodami

V. MINIMAL IMPLEMENTATION

TODO: jak dát do kódu, python - fundamentální rozdíl mezi FMode a BM

A. Forward mode

TODO: + vysvětlení pomocí duálních čísel, přetížení standardních algebraických operací tak, aby se přenášela i derivace

B. Backward mode

TODO: + vysvětlení jak se používá computational graf k zpětnému chodu

VI. USING EXISTING AUTODIF LIBRARIES IN PYTHON

TODO: předpokládám python + pytorch, tensorflow

VII. CONCLUSION

TODO: jak cca funguje autodif, k čemu je dobrá (výhody oproti FD a symbolic), důležitost pro reálné aplikace, limitace

VIII. FURTHER READING

TODO: list mých zdrojů s lepším popisem, pro ty, které by zajímalo víc

[1], [2], [3]

REFERENCES

- [1] Wikipedia contributors, “Automatic differentiation — Wikipedia, The Free Encyclopedia.” [Online]. Available: https://en.wikipedia.org/w/index.php?title=Automatic_differentiation&oldid=1339245165
- [2] Andrew Holmes, “What's Automatic Differentiation?.” [Online]. Available: <https://huggingface.co/blog/andmholm/what-is-automatic-differentiation>
- [3] Carnegie Mellon University, “Deep Learning Systems - Algorithms and Implementation.” [Online]. Available: <https://dlsyscourse.org/>